

ETICS

ROADMAP v2 — conforme au cahier des charges

Toxicité informationnelle dans les avis de rappel de produits

Des données NON structurées vers une base structurée sur les organisations

Domaine : Data for Ethics — Protection des consommateurs / Sécurité des produits

Groupe M6

Objectif en une phrase

Construire un système qui lit les communications de rappel publiées par les organisations (PDF, DOC, XLSX, HTML, images), en extrait une base de données structurée centrée sur ces organisations, et dit pour chaque document s'il est toxique au sens informationnel — c'est-à-dire s'il prive le consommateur de l'information nécessaire pour se protéger — en le comparant à la déclaration officielle RappelConso.

0. Ce qui change par rapport à la roadmap v1

La v1 était techniquement saine mais s'écartait du sujet de M. Boufarès sur l'objet d'étude. La v2 garde le même sujet (avis de rappel de produits) et le même principe « MVP d'abord », et comble les écarts avec le cahier des charges.

Point	Roadmap v1	Roadmap v2	Exigence du sujet couverte
Vocabulaire	« Transparence », 4 classes	Toxicité informationnelle + verdict binaire toxique / non toxique + 4 niveaux de sévérité	Case « Toxique ou Non » du schéma ; titre du sujet
Cadre éthique	Principe « ne pas accuser »	Légalité vs éthique comme colonne vertébrale : fiche officielle (légal) vs communication de l'organisation (éthique)	Distinction légalité / éthique (p. 2)
Corpus	Avis de rappel (source non précisée)	Deux sources par rappel : fiche RappelConso (référence) + communication de l'organisation (objet analysé)	Documents des organisations
Base de données	Centrée produits / risques	Centrée organisations (SIREN, secteur NAF, taille via API Sirene)	Phrase verte ; exemple de BD p. 5
Analyse	Classification directe par le LLM	Matrice Doc × Q1...Q7 (questions binaires avec preuves) → classe dérivée par une règle	Schéma « Filtre1, Filtre2... Doc × Q1...Qj »
Qualité des données	Validation Pydantic seule	Module dédié : complétude, exactitude, cohérence, unicité, validité, traçabilité	« Méthodes issues de la qualité des données »
Formats	PDF, HTML, texte	PDF, DOCX, XLSX , HTML, TXT, images (OCR)	« PDF, DOC, XL », « TXT, IMAGES »
LLM / Agent / Chatbot / RAG	RAG et agent optionnels, pas de chatbot	Chatbot (BD + textes), RAG avec citations, agent de complétion borné	Page 4 du sujet
Exploitations	Dashboard de comptage	Analyses Data Science : toxicité par organisation / secteur / taille, tests, clustering des formulations	Bloc « Exploitations, Analyses, Visualisations, AI/BI »
Évaluation	30–50 docs, métriques globales	150–200 docs , double annotation, κ de Cohen , split dev/test, IC bootstrap	Au-delà du sujet (point fort)

Point de vigilance n° 1 — à régler en semaine 1

Le sujet du professeur met l'accent sur les **contrats**. Le recadrage sur les avis de rappel est défendable (le titre dit « **contrats ou les documents** » et la transparence est l'un des six axes éthiques cités), mais il doit être **validé par écrit par M. Boufarès** avant de coder. Envoyer le paragraphe de positionnement de la section 1.6.

1. Positionnement dans le sujet ETICS

1.1 Sujet retenu

Détection de la toxicité informationnelle dans les communications de rappel de produits publiées par les organisations, et construction d'une base de données structurée sur ces organisations à l'aide des LLM.

1.2 Définition : la toxicité informationnelle

Le sujet ETICS parle de « toxicité textuelle » au sens large : contenus problématiques, injustes ou nuisibles, pas seulement insultants. Nous en retenons une forme précise et mesurable :

Définition opérationnelle

Une communication d'organisation est **informationnellement toxique** lorsqu'elle **prive le consommateur de l'information nécessaire pour se protéger** : le danger n'est pas nommé, la conduite à tenir est absente, le produit n'est pas identifiable, la formulation est vague, ou la gravité est atténuée par rapport à ce que l'organisation a elle-même déclaré aux autorités.

Cette définition relie directement le projet à quatre des six axes éthiques du sujet :

Axe du sujet (p. 1-2)	Traduction dans le projet
Transparence	Le risque, sa cause et l'action attendue sont-ils dits clairement ? (Q1, Q2, Q3, Q6)
Justice et équité	Le consommateur est-il informé de ses droits (remboursement, échange) ? (Q5)
Protection des personnes vulnérables	Stratification du corpus sur les produits pour enfants / puériculture ; une formulation vague pénalise d'abord les lecteurs les moins armés (Q6)
Confiance, bonne foi (conclusion p. 2)	La gravité communiquée au public est-elle cohérente avec celle déclarée officiellement ? (Q7, minimisation)

Les deux axes restants (données personnelles, discrimination) et le volet harcèlement / violence relèvent d'autres types de documents ; ils sont traités en **perspectives** dans le rapport. Le sujet les présente lui-même comme des objectifs « à terme ».

1.3 Légimité vs éthique : la colonne vertébrale du projet

Le professeur insiste : un document peut être **parfaitement légal tout en étant critiquable sur le plan éthique**. Les rappels de produits permettent de mesurer exactement cet écart, parce qu'ils existent à deux niveaux :

Niveau	Document	Nature	Rôle dans le projet
Légal	Fiche RappelConso (télédéclaration obligatoire auprès de l'État depuis 2021)	Formulaire normé, champs imposés : motif, risques, conduite à tenir...	Référence : vérité terrain pour l'extraction, gravité officielle
Éthique	Communication de l'organisation au public : communiqué, affichette magasin, page web, lettre client	Texte libre, rédigé par l'organisation, formulation choisie	Objet analysé : c'est ici que la toxicité peut apparaître

Le projet mesure donc l'écart entre **ce que l'organisation déclare aux autorités** et **ce qu'elle dit au public**. Un rappel peut être irréprochable sur RappelConso (tous les champs légaux remplis) et accompagné d'un communiqué qui parle de « léger défaut » là où la fiche mentionne un risque d'incendie.

1.4 Problématique et questions de recherche

Problématique. Un système fondé sur des LLM peut-il transformer des communications de rappel non structurées en une base de données fiable sur les organisations, et détecter les communications informationnellement toxiques avec une fiabilité comparable à celle d'annotateurs humains ?

	Question	Comment on y répond
QR1	Le LLM extrait-il correctement les informations clés (produit, risque, action, organisation) ?	Comparaison automatique aux fiches RappelConso (vérité terrain gratuite)
QR2	Le LLM détecte-t-il la toxicité aussi bien qu'un humain ?	Double annotation humaine, κ de Cohen humain-humain comme plafond, F1 du LLM
QR3	La toxicité varie-t-elle selon l'organisation, le secteur, la taille ou la catégorie de produit ?	Analyses statistiques exploratoires sur la base structurée

1.5 Principe éthique du système

- Le système **n'accuse pas** une organisation de mensonge ou de fraude. Il **signale** des communications potentiellement peu transparentes, qui méritent une vérification humaine.
- Chaque signalement est **justifié par des citations exactes** du document (champ **evidence**), vérifiées automatiquement.
- La métrique prioritaire pour la classe « toxique » est la **précision** : un faux signalement est plus coûteux, éthiquement, qu'un cas manqué.
- Toutes les sorties sont **traçables** : document source, modèle, version du prompt, date.

1.6 Paragraphe de positionnement à faire valider par l'encadrant

À envoyer à M. Boufarès en semaine 1

« Dans le cadre du projet ETICS, notre groupe (M6) propose d'étudier la toxicité informationnelle dans les communications de rappel de produits publiées par les organisations. Nous définissons comme toxique une communication qui prive le consommateur de l'information nécessaire pour se protéger. Le système extrait ces documents (PDF, DOC, XLSX, HTML, images) vers une base de données structurée centrée sur les organisations (identité SIREN, secteur, taille), pose à chaque document une série de questions (matrice Doc × Q) et produit un verdict toxique / non toxique justifié. Nous exploitons la distinction légalité / éthique en comparant la déclaration officielle RappelConso à la communication publique de l'organisation. Le projet intègre un volet qualité des données, un chatbot RAG et une évaluation sur vérité terrain annotée. Ce périmètre vous convient-il ? »

1.7 Matrice de conformité au cahier des charges

Exigence du sujet	Où dans le sujet	Réponse du projet	Section
Data for Ethics, toxicité textuelle	p. 1, titre	Toxicité informationnelle, définition opérationnelle	1.2
Légalité vs éthique	p. 2	Fiche RappelConso vs communication publique	1.3
Axes éthiques des contrats	p. 1-2	4 axes sur 6 couverts, 2 en perspectives	1.2
Documents PDF, DOC, XL, TXT, images	p. 2, schéma	Extraction multi-format + OCR	5.2
Données des organisations	p. 2, phrase verte	BD centrée organisations, API Sirene	4
Dataset structuré (BD)	p. 2, phrase verte ; p. 5	PostgreSQL relationnel + export CSV/JSON	4
Dire si le document est toxique	p. 2, phrase verte	Verdict binaire + sévérité + explication	2
Matrice Doc × Q1...Qj (filtres)	p. 2, schéma	Questionnaire Q1-Q7, table criteria_answers	2, 4
Qualité des données	p. 1	Module qualité, 6 dimensions mesurées	6
Analyse sémantique	p. 1	LLM + embeddings (RAG, clustering)	7, 9, 10
LLM	p. 4	Extraction + questionnaire	7
Agent	p. 4	Agent de complétion des données manquantes	10.3
Chatbot	p. 4	Chatbot sur la BD et les documents	10.1
RAG	p. 4	Recherche vectorielle pgvector + citations	10.2
Exploitations, analyses, visualisations, AI/BI	p. 2, schéma	Dashboard + analyses statistiques + clustering	9, 11
Traçabilité (report_source, page_reference, extraction_date)	p. 5	Tables documents et runs , champ page	4

2. Définition opérationnelle : la matrice Doc × Q1...Q7

Le schéma du professeur montre une table **Doc × Q1...Qj** : chaque document reçoit une série de questions. Nous la matérialisons par sept questions binaires. Le LLM ne classe **pas** directement le document : il répond aux questions en citant le texte, puis une **règle déterministe** en Python dérive la classe et le verdict.

Pourquoi ce choix : une question binaire est plus facile à juger qu'une classe globale, pour l'humain comme pour le LLM ; l'accord inter-annotateurs augmente ; l'analyse d'erreurs devient précise (« le LLM rate Q2 » plutôt que « il confond deux classes »).

2.1 Les sept questions

Qi	Question posée au document	Type	Axe éthique
Q1	Le danger est-il nommé explicitement (incendie, électrocution, listeria, étouffement...) ?	Intra-document	Transparence
Q2	La cause du défaut est-elle indiquée ?	Intra-document	Transparence
Q3	La conduite à tenir par le consommateur est-elle indiquée ?	Intra-document	Transparence
Q4	Le produit est-il identifiable (référence, lot, GTIN, dates de vente ou de consommation) ?	Intra-document	Transparence
Q5	Les droits du consommateur (remboursement, échange, réparation) sont-ils indiqués ?	Intra-document	Équité
Q6	La communication contient-elle des formulations vagues ou euphémisantes (« certaines anomalies », « par précaution ») sans précision du danger ?	Intra-document	Transparence, vulnérables
Q7	La gravité communiquée est-elle atténuée par rapport au risque déclaré dans la fiche RappelConso ?	Inter-documents	Bonne foi, confiance

Q7 est la seule question qui compare deux documents : le LLM reçoit le texte de l'organisation **et** les champs « risques » et « motif » de la fiche officielle. C'est ce qui rend la minimisation mesurable au lieu d'être un jugement vague.

2.2 Règle de dérivation de la classe et du verdict

Priorité	Condition	Classe	Sévérité	Verdict
1	Q7 = oui	minimisation_potentielle	3	Toxique
2	Q1 = non ou Q3 = non ou Q4 = non	incomplète	2	Toxique
3	Q6 = oui	ambiguë	1	Toxique
4	Sinon	claire	0	Non toxique

En complément, un **score de complétude informationnelle** continu est calculé : proportion de réponses « oui » sur Q1 à Q5. Il sert aux analyses statistiques (section 9), où une variable continue est plus informative qu'une classe.

```
def derive(q: dict[str, bool]) -> tuple[str, int, bool]:
    if q["Q7"]:
        return "minimisation_potentielle", 3, True
    if not (q["Q1"] and q["Q3"] and q["Q4"]):
        return "incomplete", 2, True
```

```

if q["Q6"]:
    return "ambigue", 1, True
return "claire", 0, False

completude = sum(q[k] for k in ["Q1", "Q2", "Q3", "Q4", "Q5"]) / 5

```

2.3 Guide d'annotation

Le guide d'annotation est un livrable à part entière. Sans lui, les annotations ne sont pas reproductibles et l'évaluation ne vaut rien.

1. **Rédaction (S1)** : pour chaque question, une définition, 3 exemples positifs, 3 exemples négatifs et les cas limites (ex. : « par mesure de précaution » seul → Q6 = oui ; accompagné du danger nommé → Q6 = non).
2. **Pilote (S4)** : les deux membres annotent les mêmes 20 documents à l'aveugle.
3. **Calibration** : calcul du κ par question, discussion des désaccords, révision du guide.
4. **Annotation définitive (S6-7)** : double annotation d'au moins 40 documents pour le κ final ; les autres sont annotés une fois puis relus.
5. **Consensus** : les désaccords sont tranchés ensemble et forment la vérité terrain finale.

3. Constitution du corpus

3.1 Trois couches de données par rappel

Couche	Source	Rôle	Formats
Légale	Fiches RappelConso (open data, API publique, data.economie.gouv.fr)	Référence : vérité terrain pour l'extraction, gravité officielle pour Q7	JSON (API)
Éthique	Communications des organisations : communiqués de presse, affichettes magasin, pages web de la marque, lettres aux clients, listes de lots	Objet analysé : extraction et questionnaire Q1-Q7	PDF, DOCX, XLSX, HTML, TXT, images
Organisation	API Sirene (INSEE)	Identité légale : SIREN, code NAF, tranche d'effectif	JSON (API)

Extension possible : **Safety Gate** (ex-RAPEX), le système d'alerte européen, pour comparer la France à d'autres pays de l'UE.

3.2 Taille et échantillonnage

Étape	Volume	Usage
Squelette (S2-3)	5 paires fiche + communication	Faire tourner tout le pipeline de bout en bout
MVP (S4-5)	60 paires	Pilote d'annotation, premiers prompts
Corpus final (S6-7)	150 à 200 paires	Évaluation : 40 en dev (mise au point des prompts), le reste en test (jamais vu pendant la mise au point)

Échantillonnage stratifié, sinon les classes rares n'existent pas dans les données :

- Par **catégorie de produit** : alimentaire, appareils électriques, jouets et puériculture, cosmétiques, automobile, autres.
- Sur-représentation des **produits pour enfants** (axe « personnes vulnérables »).

- Sur-échantillonnage des **cas suspects** repérés par une première passe du LLM, pour obtenir assez d'exemples « ambiguë » et « minimisation ».
- Diversité des **formats** : au moins 10 % d'images ou de PDF scannés, et quelques DOCX / XLSX.

3.3 Critères d'inclusion

- Une fiche RappelConso **et** au moins une communication de l'organisation retrouvable pour le même rappel.
- URL source conservée, fichier archivé localement dans **data/raw/** (les pages web disparaissent).
- Empreinte **SHA-256** de chaque fichier pour détecter les doublons et garantir l'intégrité.

Point de vigilance n° 2 — le vrai coût du corpus


Retrouver la communication de l'organisation correspondant à chaque fiche RappelConso est un travail **semi-manuel** : recherche sur le site de la marque, dans la presse, sur les affichettes publiées. Comptez **1 à 2 minutes par rappel quand on trouve, beaucoup plus quand on ne trouve pas**. C'est le poste le plus sous-estimé du projet : commencer la collecte dès la semaine 2.

3.4 Arborescence des données

```
data/
├── raw/                # fichiers originaux, jamais modifiés (PDF, DOCX, XLSX, HTML, PNG/JPG)
│   └── R0001/          # un dossier par rappel : fiche.json + communications
├── extracted/          # texte brut extrait, un .txt par document (+ indicateur OCR)
├── processed/          # JSON validés par Pydantic, prêts pour la base
├── annotations/        # annotations humaines (A, B, consensus)
└── exports/            # dataset final CSV / JSON
```

4. Base de données structurée centrée sur les organisations

Conformément à la phrase verte du sujet et à l'exemple de la page 5, l'entité pivot est l'**organisation**. Un rappel appartient à une organisation ; une organisation publie un ou plusieurs documents par rappel.



4.1 Tables

Table	Champs principaux	Rôle
organizations	org_id, name, siren, naf_code, sector, size_category (PME/ETI/GE), headcount_range, country, sirene_match_score	Identité légale des organisations (cf. p. 5 du sujet)
recalls	recall_id, rappelconso_id, org_id, product_name, brand, product_category, publication_date, official_reason, official_risk, official_action, gtin	Référence légale : la fiche RappelConso
documents	document_id, recall_id, org_id, doc_type (communiqué, affichette, page web, lettre, liste), format, source_url, file_path, sha256, collected_at, raw_text, ocr_used, n_pages	Traçabilité du document source


Table	Champs principaux	Rôle
extractions	extraction_id, document_id, run_id, product_name, risk_type, risk_description, consumer_action, compensation, page_reference	Données extraites par le LLM
criteria_answers	document_id, run_id, question_id (Q1-Q7), answer, evidence, evidence_verified, agreement_rate	Matrice Doc × Q au format long
toxicity_assessments	assessment_id, document_id, run_id, transparency_class, severity, is_toxic, completeness_score, explanation	Verdict final
annotations	document_id, annotator (A / B / consensus), question_id, answer, comment	Vérité terrain humaine
quality_checks	check_id, run_at, table_name, field, dimension, value, threshold, passed	Résultats du module qualité
runs	run_id, model_name, prompt_version, temperature, n_samples, git_commit, started_at, duration, cost, n_errors	Journalisation et reproductibilité

La matrice Doc × Q du professeur, avec une colonne par question, est obtenue par une **vue SQL pivot** sur **criteria_answers**. Le format long reste préférable pour stocker, car il accueille les réponses de plusieurs runs et de plusieurs annotateurs sans changer le schéma.

```
CREATE VIEW doc_q_matrix AS
SELECT document_id,
       bool_or(answer) FILTER (WHERE question_id = 'Q1') AS q1_risque_nomme,
       bool_or(answer) FILTER (WHERE question_id = 'Q2') AS q2_cause,
       -- ... Q3 à Q7
FROM criteria_answers
WHERE run_id = (SELECT max(run_id) FROM runs)
GROUP BY document_id;
```

5. Architecture et pipeline technique

5.1 Vue d’ensemble, alignée sur le schéma du professeur



5.2 Étapes détaillées

#	Étape	Ce qu'elle fait	Outil
1	Ingestion	Récupère les fiches via l'API RappelConso ; archive les communications collectées ; attribue un identifiant et un SHA-256	requests, hashlib
2	Extraction multi-format	PDF textuel → texte ; PDF scanné ou image → OCR ; DOCX → paragraphes et tableaux ; XLSX → tableaux (listes de lots) ; HTML → contenu principal sans menus ni publicités	PyMuPDF, Tesseract (pytesseract, langue fra), python-docx, pandas + openpyxl, trafilatura
3	Nettoyage	En-têtes et pieds répétitifs, espaces, césures, encodage ; conservation du numéro de page	Python, regex
4	Rattachement organisation	Du nom du fabricant au SIREN via l'API Sirene ; score de correspondance ; vérification manuelle sous un seuil	API Sirene, rapidfuzz
5	LLM : extraction	Texte → JSON conforme au schéma (produit, risque, action, droits, page)	API LLM à sortie structurée + Pydantic
6	LLM : questionnaire	Réponses Q1-Q7 avec citations ; Q7 reçoit aussi la fiche officielle ; 5 tirages pour mesurer l'accord	Même API
7	Vérification des preuves	Chaque citation doit être une sous-chaîne du texte source (après normalisation) ; sinon la réponse est marquée non vérifiée	Python
8	Dérivation du verdict	Règle déterministe de la section 2.2 (pas de LLM)	Python
9	Stockage et journalisation	Insertion en base ; enregistrement du run (modèle, prompt, commit, coût)	SQLAlchemy, PostgreSQL
10	Contrôles qualité	Calcul des six dimensions de la section 6	SQL, pandas

Point de vigilance n° 3 — construire en squelette, pas en cascade

Ne pas construire les étapes l'une après l'autre sur tout le corpus. En semaine 2-3, faire passer **5 documents par toutes les étapes**, même de façon rudimentaire, jusqu'à une métrique calculée. Ensuite, chaque semaine améliore une étape d'un pipeline qui tourne déjà. Les problèmes de fond (questions mal posées, textes illisibles) apparaissent ainsi en semaine 3, pas en semaine 9.

6. Module qualité des données

Le sujet cite en premier les « méthodes issues de la qualité des données ». Ce module mesure la qualité de la base produite, dimension par dimension, et alimente la table `quality_checks` et une page dédiée du dashboard.

Dimension	Définition	Mesure dans le projet
Complétude	Les champs attendus sont-ils renseignés ?	Taux de valeurs non nulles par champ, par format de document et par catégorie de produit
Exactitude	Les valeurs sont-elles justes ?	Concordance des champs extraits avec la fiche RappelConso : égalité après normalisation (champs catégoriels), similarité sémantique + jugement humain sur échantillon (texte libre)
Cohérence	Les valeurs respectent-elles les règles métier ?	Règles : catégorie de produit compatible avec le type de risque ; date du communiqué proche de la date de la fiche ; SIREN valide (clé de Luhn)

Dimension	Définition	Mesure dans le projet
Unicité	Chaque entité n'apparaît-elle qu'une fois ?	Doublons exacts (SHA-256) et quasi-doublons (similarité cosinus des embeddings > 0,95) ; organisations en double
Validité	Les sorties respectent-elles le schéma ?	Taux de rejet Pydantic, taux de réessai, types d'erreurs
Traçabilité	Chaque valeur est-elle reliée à sa source ?	Part des valeurs avec document, page et run renseignés ; part des citations vérifiées

Livrable : un rapport qualité généré automatiquement à chaque exécution (notebook + page du dashboard), et un chapitre du rapport final qui compare la qualité selon le format d'origine (PDF textuel, OCR, HTML, DOCX).
Hypothèse testable : l'OCR dégrade la complétude et l'exactitude.

7. Couche LLM

7.1 Trois usages séparés

Usage	Entrée	Sortie
Extraction	Texte d'un document	JSON : produit, marque, risque, action, droits, page
Questionnaire	Texte du document (+ fiche officielle pour Q7)	Réponses Q1-Q7 avec citations
Chatbot	Question en langage naturel + passages retrouvés ou résultat SQL	Réponse avec sources (section 10)

Chaque usage a son propre prompt, versionné comme un fichier (`prompts/questionnaire_v3.md`) et enregistré dans la table `runs`.

7.2 Sortie structurée et validation

```
from pydantic import BaseModel, Field
from typing import Literal

class Answer(BaseModel):
    value: bool
    evidence: list[str] = Field(description="citations exactes du document")

class Questionnaire(BaseModel):
    Q1_risque_nomme: Answer
    Q2_cause: Answer
    Q3_conduite_a_tenir: Answer
    Q4_produit_identifiable: Answer
    Q5_droits_consommateur: Answer
    Q6_formulation_vague: Answer
    Q7_attenuation_vs_officiel: Answer

# La réponse du LLM est une chaîne ; Pydantic lève une erreur si elle ne respecte pas le schéma
result = Questionnaire.model_validate_json(llm_output)
```

7.3 Règles de prompt

- Répondre **uniquement à partir du document** ; si l'information est absente, répondre non, sans l'inventer.
- Chaque réponse doit citer le passage qui la justifie, **mot pour mot**.

- Les définitions et cas limites du guide d’annotation sont **inclus dans le prompt** : humains et LLM appliquent les mêmes règles.
- Température basse pour l’extraction ; tirages multiples pour le questionnaire (7.4).

7.4 Mesurer l’incertitude correctement

Un score de « confiance » écrit par le LLM dans son propre JSON **n’est pas calibré** : ce n’est pas une probabilité. À la place :

- Interroger le modèle **5 fois** par document (température > 0) et retenir la réponse majoritaire.
- Le **taux d’accord** entre les 5 réponses sert de mesure d’incertitude (colonne `agreement_rate`).
- Tracer un **diagramme de fiabilité** : exactitude en fonction du taux d’accord. Si l’exactitude croît avec l’accord, la mesure est exploitable pour trier les cas à faire vérifier par un humain.

7.5 Choix du modèle

Recommandé : un LLM accessible par API avec **sortie structurée native** (le fournisseur garantit le respect d’un JSON Schema), ce qui élimine l’essentiel des erreurs de format. Pour environ 200 documents × 6 appels, le coût reste de l’ordre de quelques euros.

Extension (P2) : comparer avec un modèle open-source exécuté localement (Ollama). La comparaison API vs local (qualité, coût, confidentialité) enrichit le rapport.

8. Vérité terrain et évaluation

8.1 Protocole

1. Séparer le corpus annoté en **dev** (40 documents, pour mettre au point les prompts) et **test** (le reste, jamais regardé pendant la mise au point). Sans cette séparation, on sur-ajuste les prompts aux données d’évaluation et les métriques sont optimistes.
2. **Geler** prompts et modèle avant d’évaluer sur le test (fin S8).
3. Faire prédire le LLM sans lui montrer les annotations.
4. Comparer, puis analyser les erreurs.

8.2 QR1 — évaluation de l’extraction

La fiche RappelConso fournit une **vérité terrain gratuite** pour les champs communs (produit, risque, conduite à tenir, catégorie). Métrique : exactitude par champ, après normalisation (champs catégoriels) ; similarité sémantique et vérification humaine sur un échantillon de 30 documents (texte libre).

8.3 QR2 — évaluation de la détection de toxicité

Niveau	Métrique	Pourquoi
Accord humain	κ de Cohen par question, sur 40 documents doublement annotés	Plafond de performance atteignable : un LLM ne peut pas être évalué au-dessus de l’accord entre humains
Par question	Precision, recall, F1 sur Q1–Q7	Beaucoup plus de signal : chaque document fournit 7 labels
Verdict binaire	Precision (prioritaire), recall, F1 de la classe « toxique »	Un faux signalement est éthiquement plus coûteux
4 classes	Macro-F1 et matrice de confusion	Voir quelles classes sont confondues
Incertain	Diagramme de fiabilité (7.4)	La mesure d’accord est-elle exploitable ?

Niveau	Métrique	Pourquoi
Toutes	Intervalles de confiance à 95 % par bootstrap	Avec 150 documents, un F1 sans intervalle n'est pas interprétable

8.4 Analyse d'erreurs

Classer chaque erreur du jeu de test dans une typologie : erreur d'OCR, information présente mais mal repérée, citation inventée, jugement ambigu (désaccord aussi entre humains), erreur de la règle de dérivation. Cette typologie est souvent la partie la plus intéressante du rapport.

9. Exploitations Data Science et BI

Le schéma du professeur se termine par « La donnée ! Qu'est-ce que l'on va en faire ? ». Une base centrée sur les organisations permet ces analyses :

Analyse	Méthode	Question traitée
Profil de toxicité par organisation, secteur (NAF), taille, catégorie de produit, année	Taux avec intervalles de confiance (Wilson)	Où se concentrent les communications toxiques ?
Facteurs associés à la toxicité	Régression logistique <code>is_toxic ~ secteur + taille + catégorie + produit_enfant</code> ; régression sur le score de complétude	QR3 (analyse exploratoire : avec 150-200 documents, la puissance statistique est limitée, à dire explicitement)
Écart légal / éthique	Pour chaque rappel : champs présents dans la fiche mais absents de la communication	Quelles informations « disparaissent » entre la déclaration officielle et le public ?
Familles de formulations	Embeddings des communications + projection UMAP + k-means	Existe-t-il des styles de communication récurrents (juridique, commercial, alarmant, minimisant) ?
Qualité selon le format	Comparaison des dimensions qualité par format	L'OCR et le HTML dégradent-ils les données ?

10. Chatbot, RAG et agent

Le sujet consacre une page entière à ces quatre notions. Le pipeline principal reste **déterministe** (reproductible, traçable, peu coûteux), et chaque notion reçoit un rôle précis et démontrable.

Notion (définition du sujet, p. 4)	Rôle dans le projet
LLM — comprendre et extraire	Extraction structurée + questionnaire Q1-Q7 (section 7)
Agent — enchaîner les tâches, poser des questions s'il manque des données	Agent de complétion des champs manquants (10.3)
Chatbot — interagir avec les données par conversation	Interface de questions sur la base et les documents (10.1)
RAG — chercher l'information avant de répondre	Recherche vectorielle dans les communications, réponses sourcées (10.2)

10.1 Chatbot

Une page de chat dans Streamlit, avec deux modes :

- **Questions sur la base** : « Quelles organisations du secteur alimentaire ont le taux de toxicité le plus élevé ? ». Le LLM génère une requête SQL exécutée avec un **rôle PostgreSQL en lecture seule**, limité à des vues préparées (pas d'accès aux tables brutes, aucune écriture possible).
- **Questions sur les textes** : « Quels communiqués parlent d'un risque d'étouffement sans donner de conduite à tenir ? ». Réponse par RAG (10.2).

10.2 RAG

1. Découper chaque communication en passages (≈ 300 mots, avec chevauchement).
2. Calculer un embedding par passage et le stocker dans **PostgreSQL avec l'extension pgvector**, ce qui évite d'ajouter une seconde base.
3. À chaque question : retrouver les k passages les plus proches, les fournir au LLM, exiger une réponse qui **cite** document_id et page.
4. Évaluation légère : 20 questions de test, vérification manuelle que les sources citées contiennent bien la réponse.

10.3 Agent de complétion

Le sujet donne comme exemple d'agent : « poser des questions s'il manque des données ». Notre agent fait exactement cela, dans un cadre borné :

- **Déclencheur** : un document dont des champs clés sont vides après extraction (organisation non rattachée, GTIN absent, catégorie inconnue).
- **Outils autorisés** (liste fermée) : interroger l'API RappelConso, interroger l'API Sirene, relancer l'extraction avec OCR, signaler le cas pour revue humaine.
- **Garde-fous** : 5 étapes maximum, chaque appel journalisé, aucune écriture en base sans validation Pydantic.
- **Mesure** : taux de champs manquants avant / après passage de l'agent.

Le rapport justifie aussi pourquoi le reste du pipeline n'est **pas** agentique : un enchaînement fixe est plus reproductible, moins coûteux et plus facile à évaluer. Le professeur attend que ce choix soit argumenté, pas que tout soit agent.

11. API, dashboard et conteneurisation

11.1 API FastAPI

Méthode et route	Rôle
POST /documents	Déposer un document (tout format) ; lance extraction et analyse
GET /documents/{id}	Texte, extraction, matrice Q1-Q7 avec preuves, verdict
GET /organizations/{id}	Fiche organisation et historique de ses rappels
GET /organizations/{id}/toxicity	Profil de toxicité de l'organisation
GET /statistics	Agrégats par secteur, taille, catégorie, année
GET /quality/report	Dernier rapport qualité
POST /chat	Question au chatbot

11.2 Dashboard Streamlit

Page	Contenu
Vue d'ensemble	Documents analysés, répartition toxique / non toxique et par classe, évolution dans le temps
Organisations	Classement, filtres par secteur et taille, fiche détaillée
Document	Texte avec preuves surlignées , matrice Q1-Q7, comparaison avec la fiche officielle, verdict et explication
Qualité des données	Les six dimensions, par format et par catégorie
Évaluation	Métriques, matrices de confusion, diagramme de fiabilité
Chatbot	Conversation avec la base et les documents

11.3 Docker

Un fichier `docker-compose.yml` lance trois services avec une seule commande (`docker compose up`) : **PostgreSQL + pgvector**, l'**API**, le **dashboard**. La démonstration devient reproductible sur n'importe quelle machine.

12. Technologies et structure du dépôt

Composant	Technologie	Rôle
Langage	Python 3.11+	Tout le projet
Extraction PDF	PyMuPDF	Texte des PDF textuels, détection des pages sans texte
OCR	Tesseract (pytesseract, pack fra)	PDF scannés et images
DOCX / XLSX / HTML	python-docx, pandas + openpyxl, trafilatura	Autres formats
Rattachement	API Sirene, rapidfuzz	Nom → SIREN
LLM	API à sortie structurée (+ Ollama en extension)	Extraction, questionnaire, chatbot
Validation	Pydantic	Contrat de données entre modules
Base de données	PostgreSQL + pgvector	Données structurées et vecteurs du RAG
ORM	SQLAlchemy	Accès à la base depuis Python
Analyse	pandas, statsmodels, scikit-learn, umap-learn	Qualité, statistiques, clustering
API	FastAPI	Exposition du système
Dashboard	Streamlit	Visualisation et chatbot
Tests	pytest	Tests des modules critiques (extraction, règle de dérivation, vérification des preuves)
Conteneurs	Docker, docker compose	Reproductibilité
Versioning	Git + GitHub (branches + pull requests)	Travail à deux

```
etics-rappels-toxicite/  
├─ data/           # raw, extracted, processed, annotations, exports  
├─ docs/           # guide d'annotation, rapport, schémas  
└─ prompts/        # prompts versionnés (extraction_v1.md, questionnaire_v3.md...)
```

```

├─ src/
│   ├── ingestion/      # API RappelConso, archivage, SHA-256
│   ├── extraction/     # pdf.py, ocr.py, docx.py, xlsx.py, html.py
│   ├── preprocessing/  # nettoyage, normalisation
│   ├── organizations/  # API Sirene, rattachement
│   ├── llm/            # client, extraction, questionnaire, schémas Pydantic
│   ├── scoring/        # vérification des preuves, règle de dérivation
│   ├── quality/        # six dimensions qualité
│   ├── database/       # modèles SQLAlchemy, vues SQL
│   ├── rag/            # découpage, embeddings, recherche
│   ├── agent/          # agent de complétion
│   └─ evaluation/      # métriques, κ, bootstrap, fiabilité
├─ api/                 # FastAPI
├─ dashboard/           # Streamlit
├─ notebooks/           # explorations, analyses
├─ tests/
├─ docker-compose.yml
├─ Dockerfile
├─ requirements.txt
└─ README.md

```

13. Planning sur 12 semaines

Rôles : **A** = pipeline de données (ingestion, extraction, base, qualité) ; **B** = LLM et évaluation (guide d'annotation, prompts, métriques, analyses). Les tâches « A+B » se font à deux.

Sem.	Objectif	A	B	Livrable
1	Cadrage	Dépôt GitHub, Docker PostgreSQL, API RappelConso testée	Guide d'annotation v0, bibliographie	Validation écrite de l'encadrant ; schémas Pydantic et BD écrits à deux (A+B)
2-3	Squelette de bout en bout	Ingestion + extraction PDF + insertion en base sur 5 rappels	Prompts v0 extraction et questionnaire, règle de dérivation, première métrique	Pipeline complet sur 5 documents ; collecte du corpus lancée (A+B)
4-5	MVP 60 paires	OCR, DOCX, XLSX, HTML ; API Sirene et table organizations	Pilote d'annotation sur 20 docs (A+B), κ, guide v1	60 paires en base, guide d'annotation révisé
6-7	Corpus final	Montée à 150-200 paires ; module qualité des données	Annotation (A+B), prompts v1 sur le dev, tirages multiples	Corpus annoté, rapport qualité automatique
8	Gel et évaluation	Vues SQL, export du dataset CSV / JSON	Gel des prompts , évaluation sur le test, IC bootstrap	Métriques QR1 et QR2
9	Analyses	Comparaison qualité par format	Analyse d'erreurs, régressions, clustering	Résultats QR3, typologie des erreurs
10	Application	FastAPI	Dashboard Streamlit	API + dashboard fonctionnels
11	Chatbot, RAG, agent	pgvector, agent de complétion	Chatbot (SQL lecture seule + RAG), évaluation légère	Module conversationnel démontrable
12	Livraison	docker compose, README, tests	Rapport, slides	Soutenance (A+B)

13.1 Priorités : que couper en cas de retard

Niveau	Contenu	Règle
P0 — indispensable	Corpus ≥ 100 paires, extraction multi-format (PDF + OCR au minimum), BD centrée organisations, matrice Doc × Q, verdict toxique, module qualité, évaluation avec κ et IC, dashboard simple	Sans cela, le cahier des charges n'est pas respecté
P1 — attendu	Chatbot + RAG, agent de complétion, FastAPI, Docker, analyses statistiques et clustering, DOCX / XLSX	Couvre la page 4 du sujet et la valeur portfolio
P2 — extensions	Comparaison avec un LLM local, Safety Gate européen, fine-tuning, autres types de documents (contrats)	Seulement si P0 et P1 sont terminés ; sinon en perspectives

Point de vigilance n° 4 — la charge réelle

Le planning est **réaliste pour deux personnes** si chacun y consacre environ 10 à 12 heures par semaine en plus des cours. Les deux postes les plus coûteux ne sont pas techniques : la **collecte des communications** (S2 à S7) et l'**annotation** (environ 20 heures chacun). Si la semaine 5 se termine sans 60 paires en base, basculer immédiatement les éléments P1 en perspectives.

14. Travail à deux : règles de collaboration

- **Découper selon les interfaces.** Les schémas Pydantic et le schéma SQL sont le contrat entre A et B. Ils sont écrits ensemble en semaine 1, puis chacun travaille sans bloquer l'autre.
- **Une branche par fonctionnalité** (`git checkout -b feature/ocr`), une pull request sur GitHub, relue par l'autre avant fusion dans `main`. Personne ne travaille directement sur `main`.
- **Annotations indépendantes.** Pour le κ, chacun annote sans voir les réponses de l'autre (deux fichiers séparés dans `data/annotations/`).
- **Point hebdomadaire de 30 minutes** : ce qui est fait, ce qui bloque, ce qui change dans les interfaces.
- **Tableau des tâches** : GitHub Projects (une carte par tâche du planning).

15. Risques et réponses

Risque	Réponse
L'encadrant refuse le recadrage	Demande de validation en semaine 1 ; en cas de refus, le même pipeline s'applique aux conditions générales (clauses abusives), seuls le corpus et les questions changent
Communications d'organisations introuvables	Collecte dès S2 ; accepter les affichettes et pages web ; seuil minimal de 100 paires en P0
Classes trop subjectives	Questions binaires, guide d'annotation avec cas limites, κ mesuré, consensus
Trop peu de cas toxiques	Échantillonnage stratifié et sur-échantillonnage des cas suspects
Hallucinations du LLM	Sortie structurée, citations obligatoires vérifiées automatiquement, verdict dérivé par règle
Sur-ajustement des prompts	Séparation dev / test, gel des prompts avant l'évaluation
OCR de mauvaise qualité	Mesure dédiée dans le module qualité ; résultat exploité comme une conclusion du projet
Pipeline trop complexe	Squelette de bout en bout en S2-3 ; niveaux P0 / P1 / P2

Risque	Réponse
Perte de traçabilité	SHA-256, table runs, prompts versionnés, commit Git enregistré

16. Livrables finaux

Livable	Exigence du sujet
Corpus archivé (fiches + communications multi-format) avec métadonnées	Documents PDF, DOC, XL, TXT, images
Base PostgreSQL centrée organisations + dataset exporté CSV / JSON	Dataset structuré sur les organisations
Matrice Doc × Q1–Q7 et verdict toxique / non toxique par document	Dire si le document est toxique ; schéma Doc × Q
Pipeline Python reproductible (multi-format, OCR, rattachement Sirene)	Boîte noire du schéma
Module qualité des données et rapport qualité	Méthodes de qualité des données
Guide d'annotation et vérité terrain annotée	Rigueur scientifique (au-delà du sujet)
Rapport d'évaluation : κ , F1, IC, matrices de confusion, analyse d'erreurs	Rigueur scientifique (au-delà du sujet)
Analyses Data Science : profils de toxicité, régressions, clustering	Exploitations, analyses, AI/BI
Chatbot + RAG, agent de complétion	LLM, Agent, Chatbot, RAG (p. 4)
API FastAPI, dashboard Streamlit, docker compose, README	Visualisations ; démonstration
Mémoire : problématique, méthode, résultats, limites, perspectives (contrats, harcèlement, données personnelles)	Ensemble du sujet

16.1 Liste de contrôle avant la soutenance

- Le mot « toxicité » et sa définition apparaissent dès l'introduction du rapport.
- La distinction légalité / éthique est illustrée par au moins un exemple réel (fiche vs communiqué).
- La matrice Doc × Q est montrée sous la forme du schéma du professeur.
- La base est présentée à partir de la table organizations.
- Le chapitre qualité des données présente les six dimensions mesurées.
- Chaque notion LLM / agent / chatbot / RAG est démontrée ou son absence est justifiée.
- Les métriques sont données avec intervalles de confiance et comparées au κ humain.
- La démonstration se lance avec `docker compose up`.

Résumé à retenir

Cœur du projet : collecter (deux sources par rappel) → extraire (multi-format) → structurer (BD organisations) → interroger (Doc × Q1–Q7) → juger (toxique ou non) → contrôler (qualité) → évaluer (κ , F1, IC) → exploiter (analyses, chatbot).

Question scientifique : un LLM peut-il détecter la toxicité informationnelle des communications de rappel avec une fiabilité proche de celle d'annotateurs humains ?

Priorité : squelette de bout en bout en semaine 3, validation de l'encadrant en semaine 1.